Évaluation de la recherche

Requêtes de test, résultats et commentaires : comment le système retrouve les paragraphes d'IFRS 17

IFRS 17 Copilot · Selmi Yassine · Yasmine Attyaoui · Maha Aloui

Octobre 2026 · données fictives uniquement

1. Ce qui est mesuré, et comment

La recherche doit remettre au LLM, parmi les 380 paragraphes indexés du règlement (UE) 2021/2036, ceux qui répondent à la question. Chaque requête de test porte un ou plusieurs paragraphes attendus (*gold*), parfois des paragraphes « acceptables » qui répondent aussi. Mesures : **Recall@5** (part des paragraphes attendus parmi les 5 remis au LLM), **MRR** (rang du premier bon paragraphe), et **rappel à budget de 1 000 tokens** : à nombre de morceaux égal, un découpage en grandes fenêtres gagne mécaniquement en envoyant plus de texte ; à budget égal, la comparaison est juste (D-014). Les écarts sont donnés avec un intervalle de confiance à 95 % (bootstrap apparié).

Jeu	Taille	Rôle	Origine
Mise au point	56 questions (50 notées, 6 pièges)	Développer et régler	Rédigées avec Claude dans le vocabulaire de la norme
Quiz du cours	15 questions	Test hors échantillon	Quiz du cours IFRS 17 de l'équipe (EAM 2024), vocabulaire d'enseignant
Cas pratiques	30 questions	Test, mesuré une fois par méthode	Rédigés avec Claude, relus et validés par l'équipe (30/30), **gelés dans Git avant tout développement** (D-047)

2. Exemples de requêtes de test

Id	Question	Paragraphe attendu
q01	À partir de quelle date un assureur doit-il reconnaître un groupe de contrats qu'il a émis ?	25
q02	De quoi se compose l'évaluation d'un groupe de contrats au moment de sa première comptabilisation ?	32
q25	Quels taux faut-il utiliser pour l'actualisation, l'intérêt capitalisé sur la CSM et les autres évaluations ?	B72
q46	Comment traiter les contrats onéreux à l'origine puis lors des évaluations ultérieures ?	47, 48
c01	Combien de types de passifs a-t-on dans le modèle général, et quels sont-ils ?	40
c02	À quelle maille doit-on comptabiliser et évaluer les passifs d'assurance ?	16
c06	Comment comptabiliser un écart d'expérience sur les sinistres de la période ?	B97
p01	Un fabricant d'électroménager offre deux ans de réparations gratuites sur ses lave-linge. Cette garantie relève-t-elle d'IFRS 17 ?	7
p02	Une société de dépannage automobile facture un abonnement annuel fixe couvrant un nombre illimité d'interventions. Peut-elle appliquer IFRS 15 plutôt qu'IFRS 17 ?	8
p14	En méthode simplifiée, la hausse des sinistres laisse penser que notre portefeuille auto annuel perd de l'argent. Quel calcul faire ?	57
p23	Des primes encaissées cette année pour la couverture des années suivantes ont dépassé les prévisions. La marge change-t-elle ?	B96

Les pièges du jeu de mise au point (hors IFRS 17, ou réponse absente de la norme) servent au test de refus de l'agent RAG : 6/6 refusés, 0 faux refus sur les 50 autres questions.

3. Deux stratégies de découpage

A : fenêtres de 512 tokens, chevauchement de 64 (138 morceaux). **B** : un morceau par paragraphe de la norme, sans chevauchement, précédé de son chemin (annexe, section, intertitres) : 380 morceaux, 127 tokens en médiane.

Configuration	Mise au point (50)			Cas pratiques (30)			Tokens pour 5 résultats
	Recall@5	Rappel 1 000 t.	MRR	Recall@5	Rappel 1 000 t.	MRR	
A · bm25	0,650	0,470	0,492	0,450	0,250	0,308	2384
B · bm25	0,563	0,533	0,469	0,450	0,417	0,302	972
A · dense	0,750	0,493	0,509	0,517	0,383	0,406	2401
B · dense	0,817	0,757	0,650	0,550	0,517	0,420	1071
A · hybride	0,640	0,480	0,500	0,583	0,450	0,412	2395
B · hybride	0,703	0,693	0,569	0,583	0,450	0,386	1040

Commentaire. À budget égal, B l'emporte nettement sur le jeu de mise au point (dense : rappel à 1 000 tokens 0,757 contre 0,493) en envoyant deux fois moins de texte, et il permet de citer le paragraphe exact. Sur les cas pratiques, l'écart va dans le même sens mais n'est pas significatif (dense, rappel à 1 000 tokens : +0,133, IC [−0,067 ; +0,333]) : 30 questions, c'est peu. B est retenu pour la citation et le coût, pas pour un gain de rappel prouvé sur tous les jeux.

4. Améliorations essayées (Recall@5, découpage B)

Configuration	Mise au point	Quiz du cours	Cas pratiques
BM25 + glossaire (référence lexicale)	0,663	0,200	0,450
Hybride BGE-M3 + glossaire (recherche en un coup)	0,833	0,267	0,517
… + index de questions	0,847	0,200	0,617
… + graphe des renvois	0,813	0,267	0,550
… + index de questions + graphe (mode rapide)	0,847	0,267	0,683
… + reranker bge-reranker-v2-m3 (D-053)	0,853	—	0,617
Agent de recherche LangGraph (retenu, D-050)	**0,883**	**0,400**	**0,750**
Agent + reranker (D-054, rejeté)	0,953*	0,467	0,650

* exécution faite avec l'index des questions et le graphe actifs (D-054). Le reranker n'a pas été mesuré sur le quiz. Recherche par défaut : 30 candidats denses et 30 BM25 fusionnés par RRF (k = 60), top-k = 5, filtre de zone dans Qdrant ; reranker sur les 20 premiers candidats quand un GPU est disponible.

5. Commentaires

Ce qui marche. L'agent de recherche LangGraph (planifier en nommant le mécanisme d'IFRS 17 en jeu, chercher, noter chaque passage, au plus une nouvelle recherche) est la seule méthode qui gagne significativement sur les cas pratiques : Recall@5 +0,233 [+0,100 ; +0,367], MRR 0,351 → 0,668. Exemples : p04 et p05 (séparer une composante d'épargne ou un service accessoire, §11 et §12), p14 (groupe déficitaire en PAA, §57), p23 (ajustement de la CSM pour services futurs, B96) passent de 0 à 1. Coût : 2,2 appels LLM et environ 10 s de plus par question ; l'agent relance une recherche dans 6 cas sur 30.

Ce qui ne marche pas, et pourquoi. Le quiz du cours reste bas (0,400 au mieux) : un enseignant écrit « maille » là où la norme dit « niveau d'agrégation », ou « option OCI » là où elle décrit le choix de ventiler les produits et charges financiers (F-012). Deux remèdes ont été rejetés par la mesure : la réécriture de requête par le LLM (plafond inchangé à 0,267, tokens +46 %, D-045) et le fine-tuning contrastif de BGE-M3 sur un T4 (0,200 → 0,200, D-046) ; régler le glossaire sur le quiz aurait été de l'ajustement sur le jeu de test. Le glossaire de sigles aide sur la mise au point (BM25 : +0,09, IC [+0,02 ; +0,16]) mais pas sur les cas pratiques (F-014). Les

améliorations ne s'additionnent pas : l'agent avec le reranker recule à 0,650 sur les cas pratiques (D-054), et l'agent avec l'index de questions et le graphe ne fait pas mieux que l'agent seul (D-051).

Configuration retenue. Agent LangGraph sur la recherche hybride BGE-M3 + BM25 + glossaire, découpage B, Qdrant. Mode rapide sans appel LLM pour la recherche : index de questions + graphe des renvois (cas pratiques 0,683). **Limites.** Jeux petits (15 à 56 questions) et rédigés en partie avec l'aide d'un LLM ; un seul document indexé ; la qualité des réponses complètes est mesurée à part (relecture humaine de 50 réponses : 43 sans erreur, 37 complètes).

Sources : eval/retrieval_report.md, eval/retrieval_report_cas_pratiques.md, eval/retrieval_report_course_quiz.md, eval/agentic_report_*.md ; décisions D-013 à D-017, D-045 à D-054 (docs/decisions.md). Reproduire : `python -m eval.eval_retrieval` et `python -m eval.eval_agentic`.